

Master akademske studije  
**Veštačka inteligencija sa primenama**

## **SEMINARSKI RAD**

### **Analiza sentimenta filmskih recenzija primenom Transformer arhitekture**

*IMDB Dataset of 50K Movie Reviews*

Student: Đorđe Dragović

Broj indeksa: 582/2024

Jul 2026.

# Sadržaj

|                                                 |    |
|-------------------------------------------------|----|
| 1. Uvod .....                                   | 3  |
| 2. Dataset i analiza podataka .....             | 4  |
| 2.1. Opis skupa podataka .....                  | 4  |
| 2.2. Eksploratorna analiza (EDA).....           | 4  |
| 3. Preprocessing pipeline .....                 | 6  |
| 4. Treniranje modela .....                      | 7  |
| 4.1. Arhitektura .....                          | 7  |
| 4.2. Postupak treniranja i kros-validacija..... | 7  |
| 4.3. Pretraga hiperparametara.....              | 7  |
| 5. Metrike modela .....                         | 9  |
| 6. Front-end aplikacija.....                    | 11 |
| 7. Docker kontejner .....                       | 12 |
| 8. Zaključak.....                               | 13 |
| Literatura.....                                 | 14 |

## 1. Uvod

Analiza sentimenta je jedan od osnovnih zadataka obrade prirodnog jezika u kome se utvrđuje emocionalni stav izražen u tekstu. U ovom radu rešava se konkretan problem: na osnovu teksta filmske recenzije potrebno je automatski odrediti da li je recenzija **pozitivna** ili **negativna**. Reč je o **binarnoj klasifikaciji teksta**, problemu nadgledanog mašinskog učenja.

Za rešavanje problema izabrana je **Transformer** arhitektura, zasnovana na mehanizmu pažnje (engl. attention). Za razliku od rekurentnih mreža (RNN, LSTM) koje sekvencu obrađuju element po element i imaju izražen problem nestajanja gradijenata na dugim sekvencama, Transformer sve reči obrađuje paralelno i svakoj reči omogućava da direktno „pogleda“ sve ostale reči u recenziji. Time se efikasno modeluju dugoročne zavisnosti koje određuju sentiment (na primer, negacija „not“ ispred reči „good“).

Rad je nastao kao proširenje domaćeg zadatka i obuhvata kompletan životni ciklus modela mašinskog učenja: eksploratornu analizu podataka, reproduktivan preprocessing pipeline, implementaciju Transformer enkodera od nule u PyTorch-u, treniranje sa kros-validacijom i pretragom hiperparametara, praćenje eksperimenata pomoću MLflow alata, izradu korisničkog interfejsa u Streamlit biblioteci i pakovanje kompletne aplikacije u Docker kontejner.


## 2. Dataset i analiza podataka

### 2.1. Opis skupa podataka

Korišćen je javno dostupan skup **IMDB Large Movie Review Dataset**, koji sadrži **50.000 filmskih recenzija** na engleskom jeziku: 25.000 za trening i 25.000 za test. Skup je savršeno uravnotežen – tačno polovina recenzija je pozitivna (labela 1), a polovina negativna (labela 0). Korišćena je zvanična, već tokenizovana verzija skupa u kojoj je svaka recenzija predstavljena kao niz celih brojeva, gde svaki broj označava rang reči po učestalosti u celom korpusu (1 = najčešća reč „the“). Pomoću inverznog rečnika (rang → reč) recenzije se po potrebi vraćaju u tekstualni oblik.


### 2.2. Eksploratorna analiza (EDA)

Pre modelovanja sprovedena je eksploratorna analiza podataka (Jupyter notebook notebooks/01\_eda.ipynb). Provereno je da skup ne sadrži prazne recenzije, nedostajuće labele ni labele van skupa {0, 1}. Balans klasa je potvrđen: 12.500 pozitivnih i 12.500 negativnih recenzija u trening skupu, zbog čega je tačnost (accuracy) pouzdana metrika, a osnovna linija slučajnog pogađanja iznosi 50%.



Slika 1. Balans klasa u trening i test skupu

Dužina recenzija je vrlo promenljiva: prosek iznosi 237.7 reči, medijana 177, a najduža recenzija ima 2.493 reči. Na osnovu raspodele dužina izabrana je dužina sekvence **max\_len = 200**, koja u potpunosti obuhvata oko 58% recenzija, dok se duže recenzije skraćuju na prvih 200 reči – dovoljno za pouzdanu procenu sentimenta uz razuman utrošak memorije i vremena.



Slika 2. Raspodela dužine recenzija sa označenom granicom  $\max \text{ len} = 200$

Point-biserial korelacija između dužine recenzije i klase iznosi svega  $r \approx 0.016$ , pa dužina nije upotrebljiv prediktor sentimenta. Analiza vokabulara je pokazala da ograničavanje na **20.000 najčešćih reči** ostavlja udeo reči van vokabulara (OOV) od samo **2.86%** tokena. Oblaci reči jasno pokazuju razliku u rečniku pozitivnih i negativnih recenzija, što opravdava pristup zasnovan na rečima.



*Slika 3. Oblaci reči – pozitivne i negativne recenzije*

### 3. Preprocessing pipeline

Svi koraci pripreme podataka enkapsulirani su u klasu `SentimentPreprocessor` (`src/preprocessing.py`), čime je postignuta puna **reproduktivnost**: identičan postupak koristi se u treningu, evaluaciji i u finalnoj aplikaciji. Pipeline obuhvata:

- **Ograničavanje vokabulara** na 20.000 najčešćih reči; ređe reči se mapiraju u zajednički OOV token (indeks 1).
- **Rezervisane tokene**: PAD (0) za dopunu kraćih sekvenci i OOV (1) za nepoznate reči; stvarne reči dobijaju indekse od 2 naviše.
- **Ujednačavanje dužine** (padding/truncation): sve sekvence se svode na tačno 200 tokena.
- **Kodiranje sirovog teksta** za aplikaciju: mala slova, izdvajanje reči, mapiranje reč → rang → indeks po identičnim pravilima kao u treningu.

Konfiguracija pipeline-a se čuva na disku (`models/preprocessor.json`) i ponovo učitava u aplikaciji, pa model u produkciji „vidi“ tekst na potpuno isti način kao tokom treniranja. Time je otklonjen čest izvor grešaka – nekonzistentna priprema podataka između treninga i upotrebe modela.

## 4. Treniranje modela

### 4.1. Arhitektura

Arhitektura je implementirana od nule u PyTorch-u, u zasebnom modulu `src/model.py`. Koristi se **enkoder** deo Transformer arhitekture, dovoljan za klasifikaciju (dekoder je potreban tek za generisanje sekvenci). Tok podataka kroz mrežu:

- **Embedding sloj** prevodi indeks svake reči u vektor dimenzije  $d_{\text{model}}$ ; vektori se skaliraju sa  $\sqrt{d_{\text{model}}}$ .
- **Poziciono kodiranje** (sinusoidno ili naučeno) dodaje informaciju o redosledu reči, jer je attention sam po sebi ne poseduje.
- **Multi-Head Self-Attention**: skalirani dot-product attention po formuli  $\text{Attention}(Q, K, V) = \text{softmax}(QK^T/\sqrt{d_k})V$ ; više glava paralelno uči različite vrste odnosa među rečima, a PAD pozicije se maskiraju.
- **Feed-Forward mreža** (Linear  $\rightarrow$  ReLU/GELU  $\rightarrow$  Linear) primenjuje se na svaki token nezavisno i uvodi nelinearnost.
- **Rezidualne veze i LayerNorm** („Add & Norm“) oko oba podsloja stabilizuju treniranje i olakšavaju protok gradijenata.
- **Maskirano usrednjavanje** (mean pooling) preko stvarnih tokena daje jedan vektor za celu recenziju, a **linearni klasifikator** dva logita (negativan/pozitivan).


### 4.2. Postupak treniranja i kros-validacija

Modeli su trenirani Cross-Entropy funkcijom gubitka i Adam optimizatorom, uz **stratifikovanu 5-fold kros-validaciju** na uravnoteženom podskupu od 8.000 recenzija (6 epoha po fold-u, batch 64). Svi random seed-ovi su fiksirani, a verzije biblioteka evidentirane, čime je obezbeđena reproduktivnost eksperimenata. Svaki eksperiment se automatski loguje u **MLflow**: hiperparametri, gubitak po epohi, metrike po fold-u i grafici.

### 4.3. Pretraga hiperparametara

Upoređeno je šest konfiguracija modela, u kojima su varirani broj slojeva, dimenzija modela, broj glava pažnje, jačina regularizacije i tip pozicionog kodiranja:

| Konfiguracija         | $d_{\text{model}}$ | Glave | Slojevi | FFN | Dropout | Poz. kod.  |
|-----------------------|--------------------|-------|---------|-----|---------|------------|
| baseline              | 64                 | 2     | 1       | 128 | 0.1     | sinusoidno |
| deeper_2_layers       | 64                 | 2     | 2       | 128 | 0.1     | sinusoidno |
| wider_d128            | 128                | 4     | 1       | 256 | 0.1     | sinusoidno |
| more_heads_4          | 64                 | 4     | 1       | 128 | 0.1     | sinusoidno |
| regularized_dropout03 | 64                 | 2     | 1       | 128 | 0.3     | sinusoidno |
| learned_positional    | 64                 | 2     | 1       | 128 | 0.1     | naučeno    |



Slika 4. Kriva učenja izabrane konfiguracije (more\_heads\_4)




## 5. Metrike modela

Kvalitet modela meren je standardnim metrikama binarne klasifikacije: tačnost (accuracy), preciznost (precision), odziv (recall), F1 skor, kao i površinama ispod ROC i PR krive (ROC-AUC, PR-AUC). Tabela prikazuje prosečne vrednosti preko 5 foldova:


| Konfiguracija         | Accuracy      | F1            | ROC-AUC | PR-AUC | Param. | Vreme/fold |
|-----------------------|---------------|---------------|---------|--------|--------|------------|
| wider_d128            | 0.835 ± 0.009 | 0.837 ± 0.009 | 0.913   | 0.912  | 2.69 M | 284 s      |
| learned_positional    | 0.832 ± 0.008 | 0.835 ± 0.008 | 0.916   | 0.914  | 1.33 M | 121 s      |
| more_heads_4          | 0.835 ± 0.006 | 0.834 ± 0.011 | 0.920   | 0.919  | 1.31 M | 192 s      |
| regularized_dropout03 | 0.836 ± 0.010 | 0.832 ± 0.011 | 0.917   | 0.915  | 1.31 M | 121 s      |
| deeper_2_layers       | 0.837 ± 0.007 | 0.830 ± 0.008 | 0.920   | 0.917  | 1.35 M | 260 s      |
| baseline              | 0.835 ± 0.006 | 0.830 ± 0.008 | 0.921   | 0.920  | 1.31 M | 134 s      |

Sve konfiguracije postižu ROC-AUC između 0.91 i 0.92, a razlike u F1 skoru (0.830–0.837) su unutar standardne devijacije, dakle statistički neznačajne. Za **finalni model** izabrana je konfiguracija **more\_heads\_4**: postiže praktično isti F1 kao najveći model (wider\_d128), ali sa **četiri puta manje parametara** (1.31 M naspram 2.69 M) i osetno bržom inferencijom – najbolji odnos kvaliteta, veličine i brzine.




Slika 5. Poređenje F1 i ROC-AUC vrednosti po konfiguraciji

Finalni model je istreniran na svih 8.000 primera i evaluiran na zvaničnom test skupu od 25.000 recenzija, gde postiže: Accuracy **0.823**, Precision **0.832**, Recall **0.809**, F1 **0.820**, ROC-AUC **0.904** i PR-AUC **0.898**. Bliskost test metrika i kros-validacionih procena pokazuje da model dobro generalizuje. U odnosu na osnovnu liniju slučajnog pogađanja (50%), rezultat jasno potvrđuje da model uči smislene obrasce iz teksta.



Slika 6. Konfuzionna matrica finalnog modela na test skupu



Slika 7. ROC kriva finalnog modela na test skupu

## 6. Front-end aplikacija

Korisnički interfejs implementiran je pomoću **Streamlit** biblioteke (`app/app.py`). Aplikacija pri pokretanju učitava sačuvani model (`models/best_model.pt`) i sačuvani preprocessing pipeline (`models/preprocessor.json`), pri čemu se model kešira (`st.cache_resource`) kako bi se učitao samo jednom.

Funkcionalnosti aplikacije:

- unos filmske recenzije na engleskom jeziku u tekstualno polje, ili izbor jednog od ponuđenih primera (pozitivan, negativan, mešoviti);
- dugme „Analiziraj“ koje pokreće predikciju i prikazuje rezultat (POZITIVNA/NEGATIVNA recenzija) sa pouzdanošću u procentima i vizuelnom trakom verovatnoće;
- panel „Kako model vidi ovaj tekst“ sa brojem prepoznatih tokena i prvim indeksima – koristan za demonstraciju rada pipeline-a;
- bočna traka sa parametrima arhitekture i metrikama modela na test skupu.

Aplikacija se pokreće komandom:

```
streamlit run app/app.py
```

nakon čega je dostupna u pregledaču na adresi `http://localhost:8501`. Pošto aplikacija koristi identičan preprocessing kao trening, garantovano je da nema odstupanja između ponašanja modela u eksperimentima i u produkciji.

## 7. Docker kontejner

Kompletna aplikacija je kontejnerizovana pomoću **Docker** tehnologije, čime je obezbeđeno da se pokreće identično na bilo kom računaru, bez ručne instalacije zavisnosti. Dockerfile polazi od zvanične `python:3.12-slim` osnove, instalira PyTorch (CPU verziju) i ostale biblioteke, kopira izvorni kod (`src/`, `app/`) i artefakte modela (`models/`), izlaže port 8501 i pokreće Streamlit server. U sliku se ne pakuju trening podaci, MLflow logovi ni notebook-ovi (`.dockerignore`), pa je slika znatno manja.

Izgradnja slike i pokretanje kontejnera:

```
docker build -t imdb-sentiment .  
docker run -p 8501:8501 imdb-sentiment
```

Nakon pokretanja, aplikacija je dostupna na `http://localhost:8501`. Definisan je i healthcheck koji proverava Streamlit endpoint, što omogućava nadzor stanja kontejnera.

## 8. Zaključak

U radu je realizovan kompletan životni ciklus sistema mašinskog učenja za analizu sentimenta filmskih recenzija: od eksploratorne analize i reproduktivne pripreme podataka, preko implementacije Transformer enkodera od nule u PyTorch-u i sistematske pretrage hiperparametara kroz 5-fold kros-validaciju sa MLflow evidencijom, do funkcionalne web aplikacije i Docker kontejnera.

Finalni model (`more_heads_4`, 1.31 M parametara) na test skupu od 25.000 recenzija postiže Accuracy 0.823, F1 0.820 i ROC-AUC 0.904, čime ubedljivo nadmašuje osnovnu liniju od 50%. Pokazano je i da veći modeli ne donose nužno bolje rezultate: konfiguracija sa više glava pažnje postigla je isti kvalitet kao duplo veći model, uz značajno manju cenu treniranja i inferencije.

Sistem je moguće dalje unaprediti treniranjem na celom skupu od 25.000 recenzija, primenom pretreniranih embedding vektora, ranim zaustavljanjem i naprednijom pretragom hiperparametara, kao i proširenjem aplikacije (npr. isticanje reči koje su najviše uticale na odluku modela).

## Literatura

- Vaswani, A. i dr. (2017). Attention Is All You Need. NeurIPS.
- Maas, A. i dr. (2011). Learning Word Vectors for Sentiment Analysis. ACL – IMDB Large Movie Review Dataset.
- Russell, S. J., Norvig, P. (2021). Artificial Intelligence: A Modern Approach, 4. izdanje. Pearson.
- Materijali sa predavanja: Transformeri i mehanizam pažnje; End-to-end ML Pipeline.
- PyTorch, Streamlit, MLflow i Docker zvanična dokumentacija.